

Introducción al curso: Modelación y Simulación 4

Temática: ciencia de los datos y analítica

Contacto

Profesor:

Nicolás Prieto

Correo:

nprieto@eafit.edu.co

Estoy disponible para agendar sesiones para resolver dudas cuando sea necesario.

Para dudas o comentarios, contactarme por correo o por Teams.

Resultados de aprendizaje

- Entiende el ciclo de vida de la analítica y cómo usarlo en problemas reales.
- Explora y representa detalladamente un conjunto de datos multidimensionales.
- Maneja modelos de aprendizaje de máquinas basados en árboles para dar solución a problemas de analítica.
- Evalúa el rendimiento de los modelos y puede poner en producción los modelos creados para su uso.

Requisitos

- Programación básica (Python)
- Álgebra lineal y Cálculo
- Correquisito: Estadística básica (correlaciones, regresión, estadística descriptiva, etc.).
- **No se requieren** conocimientos previos en analítica.
- Sería recomendado contar con interés en aprender acerca de este tema.

Temario

Módulo 1: Introducción general a la ciencia de los datos y la analítica.

- Introducción al ciclo de vida de la analítica
- Tipos y aplicaciones de la analítica
- Definición y ejemplos reales de datos de gran tamaño y alta dimensión
- Introducción a Python para el análisis de datos
- Pandas y manejo de dataframes

Temario

Módulo 2: Descripción, preparación y visualización de datos multidimensionales.

- Estrategias de carga de datos en analítica
- Agregación, combinación, pivoteo y cruce de tablas de datos
- Dimensiones de calidad de los datos
- Detección e imputación de valores nulos
- Tratamiento de Outliers univariados y multivariados
- Visualización de datos multidimensionales, histogramas, boxplot, diagramas de dispersión

Temario

Módulo 3: Introducción al modelado usando árboles de decisión

- Tipos de modelos en analítica
- Machine Learning supervisado y modelos de regresión
- Métricas en analítica para problemas de regresión
- Introducción a árboles de decisión y sus aplicaciones
- Modelos derivados de árboles de decisión (boosting y bagging)
- Ciclo de vida para crear un modelo de regresión

Temario

Módulo 4: Aplicaciones estadísticas en el ciclo de vida de la analítica.

- Comparación estadística de modelos con pruebas de hipótesis
- Métodos paramétricos y no paramétricos para crear intervalos de confianza para evaluar el rendimiento de los modelos
- Concepto y comprensión básica de coeficientes de dependencia: Pearson, Spearman, etc. Y otras estrategias para determinar la importancia de las variables

Evaluaciones

En el curso se tendrían las siguientes evaluaciones:

Examen 1: 25% (lunes 4 de agosto, semana 4)

Taller: 20%. El taller se evalúa en dos partes:

- Parte 1 (lunes 25 de agosto, semana 7), 30% de la nota del taller
- Parte 2 (lunes 15 de septiembre, semana 10), 70% de la nota del taller

Examen 2: 25% (lunes 29 de septiembre, semana 12)

Proyecto aplicado (trabajo escrito y código): 20% (lunes 10 de noviembre, semana 17)

Exposición del proyecto aplicado: 10% (lunes 10 de noviembre, semana 17)

Pautas para las evaluaciones

Los exámenes del curso pueden tener partes teóricas y partes prácticas. Las partes teóricas son partes escritas dónde se evalúa teoría y conocimiento del tema. No se puede usar ningún material de apoyo.

Las partes prácticas se hacen con ayuda del computador. Se puede usar material de apoyo para ayudarse en estas partes prácticas, tal como: notas de clase, diapositivas del curso, recursos de internet, Google, etc. Sin embargo, está **prohibido** usar medios de comunicación para hablar con otras personas.

Sobre ChatGPT y modelos similares de GenAI: En el examen 1, está **prohibido** cualquier uso de estas herramientas. En las demás evaluaciones del curso (proyecto, talleres, examen 2, etc.), se pueden usar estas herramientas para aclarar dudas puntuales de código o de teoría, sin embargo, las preguntas **no pueden ser** respondidas con textos generados por ellas. Además, las respuestas dadas en las evaluaciones serán calificadas según **los conceptos y los métodos vistos en clase**.

Horario

Lunes 6pm a 9pm. (nota: varios lunes son festivos, se enviará material de estudio y se puede agendar sesiones para revisarlo)

Descanso de 15 minutos en la mitad de la clase.

Bibliografía principal curso

- Python for Data Analysis by Wes McKinney (O'Reilly). Copyright 2022 Wes McKinney, 978-1-098-10403-0
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T.P., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide.
- John D. Kelleher, Brian Mac Namee, and Aoife D'Arcy. 2015. Fundamentals of Machine Learning for Predictive Data Analytics: Algorithms, Worked Examples, and Case Studies. The MIT Press.

Introducción general a la ciencia de los datos y la analítica.

Definición de dato

“Facts or information, especially when examined and used to find out things or to make decisions” (Diccionario de Oxford)

“In common usage and statistics, data is a collection of discrete or continuous values that convey information, describing the quantity, quality, fact, statistics, other basic units of meaning, or simply sequences of symbols that may be further interpreted.” (Wikipedia)


“Information, especially facts or numbers, collected to be examined and considered and used to help decision-making, or information in an electronic form that can be stored and used by a computer” (Diccionario de Cambridge)

Conjunto de datos multidimensionales

Por lo general, **representaremos** los conjuntos de datos (datasets) con matrices (arreglo de filas y columnas), donde sus filas son los **registros** y sus columnas las **dimensiones o variables** del conjunto.

Por ejemplo, el siguiente conjunto de datos tendría 9 registros y 6 dimensiones o variables.

Nombre	Fecha	Sexo	Peso	Estado	Estatura
Ana	10/24/1973	Mujer	69	Casado	1,68
Jaime	11/21/1988	Hombre	70	Viudo	1,70
Diego	10/31/1994	Hombre	57	Casado	1,72
Martina	10/11/2000	Mujer	25	Soltero	1,81
Pablo	08/31/1971	Hombre	59	Separado	1,65
Santiago	05/29/1971	Hombre	78	Soltero	1,83
Patricia	10/19/1977	Mujer	45	Casado	1,78
Rocío	06/26/1975	Mujer	42	Casado	1,69
Jimena	04/21/1959	Mujer	68	Viudo	1,61



Ciclo de vida de los datos

Ejemplos cotidianos de análisis de datos

- ¿A qué hora debo salir para llegar a tiempo a la universidad?


- ¿Cómo organizar las tareas que debo hacer cada día?


- ¿Qué cantidad de alimento debo comprar para lo que voy a cocinar?

- ¿Qué gastos tendré esta semana?

- ¿Cuál celular debería comprar?

Conceptos relacionados






Conceptos relacionados: otra forma de visualizar la relación


Imagen de: towardsdatascience

Machine Learning



Machine Learning: tipos

Types of Machine Learning Algorithms



Definición de Analítica


“Analytics uses data and math to answer business questions, discover relationships, predict unknown outcomes and automate decisions.” SAS

“Analytics is the process of discovering, interpreting, and communicating significant patterns in data. Quite simply, analytics helps us see insights and meaningful data that we might not otherwise detect. ” Oracle

“Analytics is a field of computer science that uses math, statistics, and machine learning to find meaningful patterns in data. Analytics – or data analytics – involves sifting through massive data sets to discover, interpret, and share new insights and knowledge.” SAP

Tipos de analítica

4 types of Data Analytics



What is the data telling you?

Descriptive: *What's happening in my business?*

- Comprehensive, accurate and live data
- Effective visualisation

Diagnostic: *Why is it happening?*

- Ability to drill down to the root-cause
- Ability to isolate all confounding information





Predictive: *What's likely to happen?*

- Business strategies have remained fairly consistent over time
- Historical patterns being used to predict specific outcomes using algorithms
- Decisions are automated using algorithms and technology

Prescriptive: *What do I need to do?*

- Recommended actions and strategies based on champion / challenger testing strategy outcomes
- Applying advanced analytical techniques to make specific recommendations

Roles en analítica



Tareas de un científico de datos



Analizar datos usando modelos y técnicas estadísticas



Desarrollar e implementar bases de datos y sistemas de recolección de información



Obtener y cruzar los datos de varias fuentes y mantenerlos actualizados



Identificar, analizar e interpretar tendencias y patrones en conjuntos de datos



Realizar filtrado y limpieza de los datos



Trabajar en conjunto con el equipo de negocio para priorizar las necesidades de la organización



Identificar y definir oportunidades de mejora para los procesos

Habilidades claves

- Curiosidad (siempre estar aprendiendo nuevos temas)

- Disciplina (siempre necesaria)


- Atención al detalle (evitar errores)

- Creatividad (atreverse a experimentar todas las posibles soluciones)

- Entender el contexto (visión holística)

- Pensamiento técnico (dividir el objetivo en varios pasos)


- Responsabilidad ética (tener cuidado con los datos y con lo que se haga con ellos)




Metodología para proyectos de analítica: CRISP-DM

Diagrama de Taylor (2017)


CRISP-DM: Explicación de cada paso






CRISP-DM:
analogía con el
fútbol

Diagrama de Taylor (2017)




CRISP-DM:
analogía con el
fútbol

Diagrama de Taylor (2017)




CRISP-DM:
analogía con el
fútbol

Diagrama de Taylor (2017)




CRISP-DM:
analogía con el
fútbol

Diagrama de Taylor (2017)




CRISP-DM:
analogía con el
fútbol

Diagrama de Taylor (2017)



CRISP-DM:
analogía con el
fútbol

Diagrama de Taylor (2017)



CRISP-DM:
analogía con el
fútbol


Diagrama de Taylor (2017)



CRISP-DM:
analogía con el
fútbol

Diagrama de Taylor (2017)

Tipos de herramientas usadas



Software populares



+ a b l e a u




Software populares



+ a b | e a u





Algunas aplicaciones generales

IMAGEN DE: [HTTPS://DATA-FLAIR.TRAINING/BLOGS/DATA-SCIENCE-APPLICATIONS/](https://data-flair.training/blogs/data-science-applications/)

Para la próxima clase y para el curso

Tener instalada la distribución Anaconda con Python 3. Usaremos el ambiente de programación **Jupyter de Anaconda** para la clase y los exámenes.

<https://www.anaconda.com/products/individual>

NOTAS IMPORTANTE PARA EXÁMENES:

1. Los exámenes deben ser realizados en los computadores de la sala de cómputo [no se puede en los computadores personales de cada uno].
2. En los exámenes se pedirá que los notebooks se entreguen en formato .ipynb y .html (usando Download as -> Html en Jupyter), por lo que se recomienda usar el ambiente Jupyter. Si alguien usa un ambiente diferente a Jupyter (como Colab), es su responsabilidad generar el html que incluya las salidas ejecutadas del código y las gráficas en el entregable.

<https://stackoverflow.com/questions/76947942/download-jupyter-notebook-ipynb-as-html>

Videos

Popular Applications of Data Science: [https://www.youtube.com/watch?v= b-filb3cps](https://www.youtube.com/watch?v=b-filb3cps)

Self driving cars explained: <https://www.youtube.com/watch?v=yt015gM-ync>

Referencias diapositivas

<https://www.coursera.org/learn/foundations-data?specialization=google-data-analytics#syllabus>

<https://online.hbs.edu/blog/post/data-life-cycle>