


Módulo 2:

Análisis exploratorio de datos




Metodología para proyectos de analítica: CRISP-DM

Diagrama de Taylor (2017)

Ejemplo de CRISP-DM

<https://medium.com/@christophberns/using-crisp-dm-to-predict-car-prices-f15eb5b14025>



Metodología para proyectos de analítica: CRISP-DM


Diagrama de Taylor (2017)

Entendimiento del negocio

Objetivo

Objetivo del Negocio/
Preguntas de negocio

Criterios de éxito
desde el negocio




Antecedentes



Estado actual

Inventario de Recursos



Requisitos, supuestos y limitaciones



[Esta foto](#) de Autor desconocido
está bajo licencia [CC BY-NC](#)

Riesgos y Contingencias



[Esta foto](#) de Autor desconocido está bajo
licencia [CC BY-SA](#)

Terminología



Costo y Beneficio



[Esta foto](#) de Autor desconocido está bajo
licencia [CC BY-SA-NC](#)

Objetivos desde la analítica

Objetivo analítico



Criterios de éxito desde la analítica



Plan de acción

Plan del Proyecto



Evaluación inicial de herramientas y técnicas



[Esta foto](#) de Autor desconocido está bajo licencia [CC BY-SA](#)

Entendimiento y preparación de los datos

Procesamiento y carga de archivos



Diccionario de datos

Nombre de Archivo: BDPlantilla

Fecha de creación: 27/04/2008.

Descripción: Base de datos que contendrá la plantilla de personal del instituto.

Campo	Tamaño	Tipo de Dato	Descripción
CURP	18	Caracter	Clave Unica de Registro de Población
cPaterno	30	Caracter	Apellido paterno del Empleado
cMaterno	30	Caracter	Apellido materno del empleado
cNombre	45	Caracter	Nombre del Empleado.
cDomicilio	60	Caracter	Domicilio actual donde reside el empleado
cColonia	45	Carácter	Colonia del domicilio donde reside el empleado
cCiudad	45	Carácter	Ciudad donde reside el empleado
cEstado	45	Carácter	Entidad federativa de residencia del empleado
cTelefono	12	Carácter	Número telefónico del empleado
nPostal	6	Numérico	Código postal del domicilio del empleado
cFamiliar	65	Carácter	Nombre de un familiar directo del empleado
FDomicilio	65	Carácter	Domicilio de familiar directo del empleado
FTelefono	12	Carácter	Teléfono de familiar directo del empleado

Relaciones:

CURP con BDNomina

Campos Clave:

CURP, cPaterno, cMaterno

Cruce de tablas (joins)

TABLE 1

Products	Price
Kiwis	\$6
Onions	\$3
Tomatoes	\$7


TABLE 2

Products	Quantity
Kiwis	10
Onions	6
Broccoli	5


INNER JOIN

Products	Price	Quantity
Kiwis	\$6	10
Onions	\$3	6


JOIN




FULL JOIN



LEFT JOIN



RIGHT JOIN




Dimensiones de calidad de datos

1. Completitud




[Esta foto](#) de Autor desconocido está bajo licencia [CC BY-ND](#)

2. Conformidad/Validez




3. Consistencia




4. Precisión/Exactitud



5. Duplicidad/Unicidad



6. Integridad



Dimensiones de calidad de datos

[preguntas guía]

1. **Completitud:** ¿Se tiene toda la información necesaria para la solución del problema o hacen falta registros o variables? ¿Cuántos valores faltantes hay? ¿Es posible completarlos?
2. **Conformidad o Validez:** Los formatos de los valores son consistentes a lo largo del conjunto de datos [ej: fechas]? Los tipos de datos son lógicos? Son entendibles? Ej: dd/mm/aaaa vs mm/dd/aaaa
3. **Consistencia:** Al comparar la información entre varias variables (columnas de una misma fila) es coherente o se contradice? Ej: un hombre que mide 1.75 m y tiene 6 años.
4. **Precisión/Exactitud:** Los datos son coherentes con la realidad (si tienen sentido y son correctos)? Que no haya datos en contra de la logica ni outliers muy evidentes. [ejemplo: una persona de 735 años].
5. **Duplicidad (Unicidad):** Verificar que haya un registro único por combinación de datos cuándo estos deben ser únicos [ejemplo: puede haber dos carros con el mismo precio, pero no con la misma placa].
6. **Integridad:** Se mira cuando hay varias fuentes/tablas de datos. Verificar que las fuentes de datos estén sincronizadas y que los cambios en una se reflejen en las otras.

Ejercicio: determinar problemas de calidad

3. Precisión

4. Consistencia

Fecha	ID	Producto	Precio Antes	Descuento	Precio Después	Cantidad	Total
30/02/2020	48939420	Gorra	20000	10	18000	1	18000
5/03/2020	65465465	Chaleco	50000	25	37500	3	75000
20/03/2020	943834032	Pantalón	40000	20	32000	3	96000
28/03/2020	454166164	Camisa	30000	20	24000	2	48000
23/03/2020	943834032	Gorra	20000	10	18000	1	18000
2/25/2020	74937493	Medias	15000	15	12750	1	12750
28/03/2020	454166164	Camisa	30000	20	24000	2	48000

2. Conformidad

1. Duplicidad

Manejo de valores faltantes

Missing values

PassengerId	Survived	Pclass	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0	3	male	22	1	0	A/5 21171	7.25		S
2	1	1	female	38	1	0	PC 17599	71.2833	C85	C
3	1	3	female	26	0	0	STON/O2. 3101282	7.925		S
4	1	1	female	35	1	0	113803	53.1	C123	S
5	0	3	male	35	0	0	373450	8.05		S
6	0	3	male		0	0	330877	8.4583		Q


	col1	col2	col3	col4	col5
0	2	5.0	3.0	6	NaN
1	9	NaN	9.0	0	7.0
2	19	17.0	NaN	9	NaN

mean()




	col1	col2	col3	col4	col5
0	2.0	5.0	3.0	6.0	7.0
1	9.0	11.0	9.0	0.0	7.0
2	19.0	17.0	6.0	9.0	7.0


Outliers: univariados



Outliers: multivariados



Outliers: multivariados (Mahalanobis)



Mirar otro ejemplo en:

[https://milania.de/showcase/From the Euclidean distance over standardized variables to the Mahalanobis distance](https://milania.de/showcase/From%20the%20Euclidean%20distance%20over%20standardized%20variables%20to%20the%20Mahalanobis%20distance)

Robustez

Suponga que se tienen las siguientes edades de alumnos (niños) de un salón, recogidas en una encuesta llenada por computador por los niños.

Robustez

Suponga que se tienen las siguientes edades de alumnos (niños) de un salón, recogidas en una encuesta llenada por computador por los niños.

Edades = [12, 14, 14, 13, 15, 144, 14]

Robustez

Suponga que se tienen las siguientes edades de alumnos (niños) de un salón, recogidas en una encuesta llenada por computador por los niños.

Edades = [12, 14, 14, 13, 15, 144, 14]

La edad promedio es de 32.3 años.

“Los niños de este salón tienen una edad promedio de 32.3 años”

Robustez

Suponga que se tienen las siguientes edades de alumnos (niños) de un salón, recogidas en una encuesta llenada por computador por los niños.

Edades = [12, 14, 14, 13, 15, 144, 14]


Mientras que la edad mediana es de 14 años.

Estadística descriptiva


Medidas Descriptivas

- Media
- Varianza / Desviación Estándar
- Mediana
- Cuartiles
- Mínimo
- Máximo
- Número de registros
- Número de nulos
- Tipos de Datos

Boxplots



Distribuciones de probabilidad



Ojo: Un análisis descriptivo implica la búsqueda de puntos de interés o patrones en las estadísticas.

Operaciones agregadas




Figure 9-1. Illustration of a group aggregation

Operaciones agregadas

También se puede agrupar por más de una llave y calcular diferentes estadísticos para cada una.

```
In [144]: tips.pivot_table(['tip_pct', 'size'], rows=['sex', 'day'],
.....:                    cols='smoker', margins=True)
Out[144]:
```


		size			tip_pct		
smoker		No	Yes	All	No	Yes	All
Female	Fri	2.500000	2.000000	2.111111	0.165296	0.209129	0.199388
	Sat	2.307692	2.200000	2.250000	0.147993	0.163817	0.156470
	Sun	3.071429	2.500000	2.944444	0.165710	0.237075	0.181569
	Thur	2.480000	2.428571	2.468750	0.155971	0.163073	0.157525
Male	Fri	2.000000	2.125000	2.100000	0.138005	0.144730	0.143385
	Sat	2.656250	2.629630	2.644068	0.162132	0.139067	0.151577
	Sun	2.883721	2.600000	2.810345	0.158291	0.173964	0.162344
	Thur	2.500000	2.300000	2.433333	0.165706	0.164417	0.165276
All		2.668874	2.408602	2.569672	0.159328	0.163196	0.160803

Escalamiento de datos




Ingeniería de características

Categorización




Características temporales


DD/MM/AAAA



Reducción de dimensionalidad




Transformación Logarítmica



Formulación de hipótesis

Plantear posibles hipótesis e intentar generar evidencias descriptivas para ver si se cumplen o no.



Formulación de hipótesis







Figure 2-7. Plot of diversity metric by year

Más adelante veremos como verificar algunas de estas hipótesis de una manera más formal.

Importancia de variables/correlacion




Visualización



Visualización:
tener cuidado

Gun deaths in Florida

Number of murders committed using firearms




Source: Florida Department of Law Enforcement

C. Chan 16/02/2014

REUTERS

Visualización: reportería




Visualización: data storytelling




Tomada de: <https://www.istockphoto.com/es/fotos/lancaster-bomber>

Visualización: data storytelling



Visualización: data storytelling




Análisis de textos



Manejo de strings

Para el análisis de textos, es muy común utilizar diversos métodos para preprocesar los textos, algunos de ellos ya los hemos visto en Python.


A screenshot of a Python Shell window titled "Python Shell". The window has a menu bar with "File", "Edit", "Shell", "Debug", "Options", "Windows", and "Help". The main text area shows the following code and output:

```
Python 3.1 (r31:73574, Jun 26 2009, 20:21:35) [MSC v.1500 32 bit (Intel)] on win
32
Type "copyright", "credits" or "license()" for more information.
>>> strDummy = "The Knights who say Ni!"
>>> strDummy.lower()
'the knights who say ni!'
>>> print(strDummy)
The Knights who say Ni!
>>> strDummy.upper()
'THE KNIGHTS WHO SAY NI!'
>>> strDummy.replace("s", "t")
'The Knightt who tay Ni!'
>>> strDummy.split()
['The', 'Knights', 'who', 'say', 'Ni!']
>>> |
```

Expresiones regulares

- A veces las operaciones básicas del tipo String no son suficiente y es necesario recurrir a procesos más avanzados, como las expresiones regulares.

Regular Expression E-mail Matching Example



ComputerHope.com

Otras referencias

https://pdf4pro.com/amp/download?data_id=73581e&slug=crisp-dm-1-the-modeling-agency-com

Python for Data Analysis. Wes Mckinney