


Módulo 3:

Introducción al Modelado:

usando árboles de decisión

Introducción al Machine learning



Definiciones de Machine learning

What is Machine Learning?


Machine Learning is a subset of AI that combines statistics & programming to give computers the ability to “learn” without explicitly being programmed.

Definition

- Machine learning, a branch of artificial intelligence, is a scientific discipline concerned with the design and development of algorithms that allow computers to evolve behaviors based on empirical data (1)


1 http://en.wikipedia.org/wiki/Machine_learning

Machine Learning



Machine Learning: tipos

Types of Machine Learning Algorithms



Ejemplos notables avanzados de ML



ChatGPT

Avances rápidos en ML: DALL-E (2021)

an illustration of a baby lemur in a cape riding a unicycle




Avances rápidos en ML: SORA (2024)

Este campo avanza a gran velocidad y toca estar constantemente actualizándose:


SORA (Febrero, 2024):

<https://www.youtube.com/watch?v=dmNI6-UBmbI>

Muchas opciones de modelos



Enfoque en aprendizaje supervisado



Regresión y clasificación




Regression



What will be the temperature tomorrow?

84°



Fahrenheit

Classification



Will it be hot or cold tomorrow?

COLD

HOT




Fahrenheit

Enfoque en modelos de regresión




Un ejemplo: Regresión lineal




Encontrar la recta de mejor ajuste

En el modelo de regresión lineal, usamos la estadística para encontrar la línea recta que mejor se ajusta a nuestro conjunto de datos.



Algunas posibles aplicaciones





CRISP-DM para
problemas de
machine learning
supervisado de
regresión

Diagrama de Taylor (2017)

Entendimiento del negocio

Identificar el problema

Identificar qué tipo de problema de analítica es el que vamos a abordar.

Esto requiere tener bien definida la necesidad de negocio a resolver.

Recordemos que en este curso nos enfocaremos solo en problemáticas que se resuelvan con modelos supervisados de regresión.

Definiciones

Todas las demás actividades correspondientes al entendimiento de negocio deben ser también realizadas para abordar un problema de modelos de regresión.

Esto incluirá definir los objetivos del proyecto, los criterios de éxito esperados, las limitaciones que este tendrá, los supuestos que se realizarán, etc.

Además, también se tendrá que elaborar el plan del proyecto y definir las herramientas que se utilizarán, tal como ocurre con todos los proyectos de analítica.

Entendimiento y Preparación de datos

Selección del conjunto de datos a usar

Uno de los primeros pasos es hacer el filtrado del conjunto de datos según el entendimiento de negocio que hicimos.

Esto incluye seleccionar solamente las columnas que nos interese incluir en el estudio y que puedan ser relevantes, y además también incluye aplicar los filtros que consideremos necesarios para conservar solo el conjunto de datos que nos interesa modelar.

Análisis descriptivo

Luego de tener seleccionado nuestro conjunto de datos, se puede hacer un primer análisis descriptivo para poder empezar a detectar patrones de interés.

Esto lo podemos hacer viendo y **analizando** los tipos de datos que tenemos, el contenido de algunas filas y sus estadísticos descriptivos, etc.

Debemos proceder a **realizar las preparaciones de datos necesarias** según lo que veamos aquí (si vemos cosas muy raras o incorrectas, hay que realizarles el tratamiento correspondiente).

Dimensiones de calidad

Luego, podemos proceder a analizar las dimensiones de calidad de datos de nuestro conjunto.

Esto incluirá tareas que ya conocemos como la detección de datos faltantes, identificación de outliers, revisión de problemas de formato o duplicidad, etc.

A partir del análisis de calidad, también procederíamos entonces a **realizar las correcciones y los tratamientos pertinentes.**

Variables categóricas

Los modelos de machine learning tendrán problemas en su fase de entrenamiento si se encuentran con variables categóricas, ya que están diseñados para trabajar con números.

Por esta razón, se deben aplicar algunas técnicas (llamadas **label encoding**) para convertir estas variables categóricas en variables numéricas que puedan ser usadas por los modelos.

Los dos tipos de label encoding más comunes son one-hot encoding y ordinal encoding.

One-hot encoding

En one-hot encoding, se asigna una columna nueva por cada categoría de la variable categórica. La columna correspondiente a la categoría toma un valor de 1 en esa fila, y las demás tienen un 0.

Esta técnica se recomienda usarla cuando la categoría es **nominal** (no hay un orden o jerarquía entre las categorías).

Human-Readable

Pet
Cat
Dog
Turtle
Fish
Cat



Machine-Readable

Cat	Dog	Turtle	Fish
1	0	0	0
0	1	0	0
0	0	1	0
0	0	0	1
1	0	0	0

Ordinal encoding

En ordinal encoding, se crea una sola nueva columna para reemplazar a la columna categórica, en la cual se le asigna un número distinto a cada una de las categorías que existen, **según cierto orden**.

Esta técnica se recomienda usarla cuando la categoría es **ordinal** (sí hay un orden o jerarquía entre las categorías).

Clima
Frío
Caliente
Templado
Templado
Muy Caliente
Muy Frío
Caliente
Templado
Un poco caliente




Clima_encoded
1
4
2
2
5
0
4
2
3

Escalamiento de las características


En árboles de decisión, el escalamiento no es tan importante: el árbol simplemente buscará de forma **independiente** las divisiones que debe hacer en cada columna sin importar sus diversas magnitudes.

Sin embargo, en otros tipos de modelos (ejemplo: regresiones lineales o redes neuronales), se suele minimizar el MSE usando gradiente descendiente, y si no se escalan los datos, el modelo tardará mucho más en converger.




Un paréntesis antes de
seguir:
Overfitting y underfitting


Evitar que los modelos solo memoricen




Minimizar Bias y variance




Overfitting y underfitting



Para resolver todo esto: Dividir en Entrenamiento, validación y prueba




Medir el error en entrenamiento y en validación o prueba





Modelos de regresión:

usando árboles de decisión


Árboles de decisión



Árboles de decisión



Arboles de decisión: ejemplo base



¿Cómo se construye el árbol?

Los algoritmos de árboles de decisión tienen métodos matemáticos que les permiten determinar cómo se debe construir el árbol para obtener mejores resultados.

Lo que buscan es que las ramificaciones que se vayan creando sean lo más útiles posibles para **dividir los datos** y permitir a partir de estos generar las predicciones.

Existen diversas fórmulas matemáticas para cada uno de estos factores (qué variable usar en la división, qué umbral usar, hasta qué punto seguir profundizando en las ramas del árbol, etc.).


Arboles de decisión: paso a paso

Cómo se dijo anteriormente, el objetivo del curso no es entrar muy a profundidad en cada uno de los componentes de un árbol de decisión ni en sus fundamentos matemáticos.

Sin embargo, miremos este ejemplo que nos ayudará a entender un poco como las máquinas pueden usar la matemática para crear estos árboles (este ejemplo es con el algoritmo ID3):

<https://kindsonthegenius.com/blog/how-to-build-a-decision-tree-for-classification-step-by-step-procedure-using-entropy-and-gain/>

La predicción no es perfecta




Arboles de decisión para regresión

Aquí también construimos nuestro árbol buscando las mejores divisiones (para más detalle, mirar: https://www.saedsayad.com/decision_tree_reg.htm).


Pero al final, si varios datos caen en el nodo hoja, la predicción será. por ejemplo, el promedio de sus valores (en caso de clasificación, era la categoría mayoritaria).

Temp.	Humidity	Windy	Hours Played
Mild	High	FALSE	45
Cool	Normal	FALSE	52
Mild	Normal	FALSE	46
Cool	Normal	TRUE	23
Mild	High	TRUE	30



Cuidado con los árboles de decisión

Los árboles de decisión pueden caer muy fácil en overfitting si memorizan todos los datos de entrenamiento.



Potenciando los árboles de decisión: Boosting y Bagging

Los árboles de decisión, a pesar de ser modelos decentes, no son tan buenos generalizándose a varios problemas y a resultados fuera del conjunto de entrenamiento.

Para resolver esto, se utilizan técnicas que combinan varios árboles de decisión (en vez de uno solo), lo cual permitirá tener modelos mucho más robustos y aptos para cualquier escenario.

Estas técnicas se conocen como boosting y bagging, y las veremos más adelante en el módulo.

Y muchos más modelos...

Para este curso, nos enfocaremos en estos tres tipos de modelos para la parte de modelado (árboles de decisión, boosting y bagging).

Sin embargo, existen muchísimos otros tipos de modelos que también sirven para problemáticas similares.

En un problema de analítica real será necesario probar también muchos otros tipos de modelos en busca de encontrar el mejor.

Selección e ingeniería de características

Esta es una de las formas en las que se pueden crear diversos modelos para luego poder ponerlos todos a competir y seleccionar el mejor. Implica realizar una correcta selección de las características (variables) a incluir en el modelo según su relevancia.

Algunas variables son más importantes que otras, esto se puede saber por: 1. ensayo y error, 2. conocimiento de negocio o 3. Usando métodos estadísticos (este último lo veremos en el siguiente módulo).

Puede implicar a veces crear nuevas características (ejemplo: si tengo una edad, y lo quiero cambiar por grupos etarios de niños, jóvenes, adultos y adultos mayores).

Tuneo de hiperparámetros

Esta es otra de las formas en las que se pueden crear diversos modelos para luego poder ponerlos todos a competir y seleccionar el mejor.

Consiste en cambiar los hiperparámetros del modelo para crear una nueva arquitectura y entrenar y evaluar cada una de ellas. Los hiperparámetros son los argumentos del modelo que definimos antes de entrenarlo y que no son estimados por este.

Por ejemplo, en el caso de árboles de decisión, podríamos definir el criterio a usar para hacer las divisiones del árbol, o el número máximo de hojas o ramas que queremos que tenga el árbol para que no sea demasiado grande, etc.

Seleccionar el mejor modelo

Ahora que tenemos varios modelos diferentes, debemos saber cómo seleccionar el mejor de ellos.

El modelo elegido será aquel que cumpla los objetivos de negocio y que además presente el mejor rendimiento.

Para medir el rendimiento de los distintos modelos, se usan métricas.

Métricas para regresión

Table – Summary of Discussed Forecasting Metrics

	Absolute	Relative
Error Measures Bias	Mean Error (ME)	Mean Percentage Error (MPE)
Absolute Error Measures accuracy	Mean Absolute Error (MAE) ←	Mean Absolute Percentage Error (MAPE) ←
Squared Error Measures accuracy, especially penalizing very bad forecast points	Mean Squared Error (MSE) ← Root-Mean Squared Error (RMSE)	Mean Squared Percentage Error (MSPE) Root-Mean squared Percentage Error (RMSPE)

Comparar y seleccionar en validación, evaluarlo en prueba

Se recomienda siempre mirar las métricas de los modelos “en dos etapas”:

- A todos los modelos de interés se les sacan las métricas en el conjunto de validación, para ponerlos a competir y **elegir el mejor de ellos.**
- Al final, al modelo elegido se le sacan las métricas en el conjunto de prueba, para evaluarlo y poder tener una **estimación de su comportamiento en condiciones reales. (esto ocurre en la etapa 5 de Evaluación),**

Opcional: k-fold cross validation



Evaluación

Ahora, evaluarlo en prueba

Ahora que tenemos nuestro modelo elegido, debemos ver cuál es su rendimiento en prueba. Para esto, entrenamos el modelo elegido usando la totalidad de los conjuntos de entrenamiento y validación, y luego predecimos y le calculamos sus métricas en el conjunto de prueba.

Las métricas en el conjunto de prueba **son las que mostrarán en realidad cómo esperamos que nuestro modelo se comporte cuando esté siendo usado a futuro por los usuarios**, por lo que estas métricas son de vital importancia para el equipo de negocio.

Debe dar parecido a validación

Las métricas del modelo en el conjunto de prueba deben dar similares a las del conjunto de validación.

Si son diferentes, esto indica que hubo un problema.

Puede ser que se le haya **hecho overfit al de validación** (se prueba tantos modelos que por simple suerte alguno da muy bueno en el de validación, pero no es bueno en condiciones reales), o porque el **conjunto de prueba no fue escogido correctamente** (no viene de la misma distribución que el de validación).


Ver si se cumplieron objetivos de negocio

En este punto, se procede a analizar el cumplimiento de los objetivos de negocio.

Se debe ver si las métricas obtenidas en prueba son suficientemente buenas para cumplir satisfactoriamente dichos objetivos, y además si había algunas otras restricciones o requisitos que se debían cumplir.

Si no se cumplen, se debe regresar a las etapas anteriores en búsqueda de pulir los modelos creados o de poner objetivos más acordes al problema.

Incluir algunas visualizaciones de los resultados obtenidos



Despliegue

Error común: solo llegar hasta la evaluación

Un error muy común es terminar todo el CRISP-DM hasta la etapa 5 y pensar que así queda bien, puesto que ya tenemos el modelo y sus resultados.

Pero aquí estamos dejando un par de preguntas sin responder:

¿Cómo puede el usuario utilizar el modelo con nuevos datos?

¿Cómo monitoreo el modelo a futuro para verificar que siga teniendo un buen rendimiento?

Debo poder usar el modelo a futuro


Si solo llego hasta el paso 5, solo hice un “estudio” de lo que pasaba, pero el modelo no podrá ser consumido más adelante.

Pensemos: en la mayoría de los casos, a una empresa de nada le sirve que el modelo prediga los datos que ya la empresa conoce, sino que necesita el modelo para hacer predicciones cada vez que le lleguen nuevos datos.

Por esta razón, debo desplegar el modelo para que pueda ser usado a futuro cuando nos lleguen nuevos datos que queramos predecir, el cual es su verdadero fin.

Algunas formas de desplegar

Una forma es que haya una interfaz básica que pida seleccionar un archivo con nuevos datos y retorne un archivo nuevo con las predicciones generadas.



Algunas formas de desplegar

Otra opción puede ser un menú básico en el que el usuario ingrese los valores y se retorne la predicción. El menú puede ser muy simple o muy avanzado.

BANGLORE HOUSE PRICE PREDICTION

LOCATION	BHK
old airport road	2
AREA	BATHROOMS
1500	2
ESTIMATE PRICE	

ESTIMATED PRICE:
1.02 Crore

Despliegues avanzados


En un proyecto a mayor escala, estos despliegues no suelen ser suficientes.

En dichos casos, se suelen hacer despliegues que involucran muchas más cosas:

- Despliegue en la Nube (el cómputo del modelo a través de Internet).
- Scheduled runs (ejecutar un modelo por ejemplo todos los días a las 8:00am).
- Ejecución bajo demanda (qué el modelo sea capaz de recibir peticiones de usuarios y retornar las predicciones correspondientes para ellas).


Despliegues avanzados

En términos generales, a veces pueden ser algo como esto:



Despliegues avanzados

Pero en la realidad se puede volver mucho más complicado:




Opcional: monitoreo a futuro y data drift

Por último, a futuro se debe ir monitoreando el modelo para ver que siga teniendo un buen rendimiento.

Este tema no lo veremos en el curso, pero es bueno mencionarlo, ya que es importante en un proyecto real monitorear que un modelo no pierda rendimiento con el tiempo y se descalibre.

Muchas veces esto se da por algo llamado **Data Drift**, lo cual ocurre cuando la distribución de los datos ha cambiado con el tiempo, por lo que el modelo entrenado previamente ya no es apto para los nuevos datos que llegan.


Caso notable



Caso notable

En 2020 muchos modelos se descalibraron por causas relacionadas con la pandemia de COVID 19.

Número de peatones en las calles de Melbourne



Conclusión final

Al final se debe validar si se cumplieron bien todas las etapas de CRISP-DM.

Si el objetivo no se cumple, toca devolverse en el ciclo y repetir las etapas que sean necesarias.

Dicha decisión de si se cumplió el objetivo final o no debe tomarse en conjunto con el equipo de negocio.

