


Resumen hasta ahora



CRISP-DM

Diagrama de Taylor (2017)

Aplicaciones de modelos supervisados de regresión en diversas áreas

- Aseguradoras: ¿Qué edad se espera que viva una determinada persona? ¿Qué valor debo cobrar por un seguro según lo que incluye?
- Bancos: ¿Cuánto dinero se espera que entre y salga de los fondos de inversión? ¿Cuántos usuarios nuevos se esperan este año?
- Publicidad: ¿Cuántas personas verán mi anuncio? ¿Cuántas personas darán click en él? ¿Cuántos comprarán el producto?
- Eléctrico: ¿Cuánta energía eléctrica se demandará hoy? ¿Qué tanto viento habrá para mi planta de energía eólica? ¿Cada cuánto debo hacer mantenimiento preventivo a los equipos?
- Retail (supermercados, almacenes): ¿Cuántas personas visitarán mi tienda? ¿Cuántas unidades debo mantener en inventario? ¿Cuánto tardará en llegar el pedido de un producto?
- Moda: ¿Cuántas unidades de cada prenda venderé? ¿Cuántas prendas serán cambiadas por talla durante este mes? ¿Cuál es la vida útil de una prenda?

Aplicaciones de modelos supervisados de regresión en diversas áreas

- Deporte: ¿Cuál es el precio que debería costar un determinado jugador? ¿Cuántos puntos conseguirá en total un equipo al final de la temporada? ¿Cuántos aficionados se esperan en el estadio?
- Videojuegos: ¿Cuántas personas descargarán un juego? ¿Cuánto tarda un jugador en completar el juego? ¿Qué tantos usuarios concurrentes puedo esperar?
- Salud: ¿Cuál debería ser mi ritmo cardíaco óptimo? ¿Cuántas personas se contagiarán de un cierto virus? ¿Cuántos médicos debo tener en mi empresa para atender a la población?
- Finanzas: ¿Cuál será el valor del dólar en los siguientes días? ¿Y del bitcoin?
- Viajes: ¿Cuál será el rating promedio que los usuarios le darán a un cierto hotel? ¿Qué precio se debería cobrar por el paquete de viaje?

Y muchos más. ¿Algún otro ejemplo que se les ocurra?

Proyecto del curso

En el proyecto aplicado de esta materia, podrán elegir una problemática de la industria que deseen, y que sea relacionada con modelos supervisados de regresión.

Tendrán que aplicar todas las etapas de CRISP-DM vistas en el curso para abordar de principio a fin esta problemática y darle una solución.

Módulo 4:

Estadística en analítica

Introducción

La estadística juega un papel fundamental en cualquier tipo de proceso analítico.


De este modo, existen gran número de diversas aplicaciones estadísticas para cada una de las fases del ciclo de vida analítico.

Estadística descriptiva


Medidas Descriptivas

- Media
- Varianza / Desviación Estándar
- Mediana
- Cuartiles
- Mínimo
- Máximo
- Número de registros
- Número de nulos
- Tipos de Datos

Distribuciones de probabilidad



Boxplots



Pruebas de hipótesis




Testing Hypothesis on the Mean with Variance Known (Z-Test)– Example 16.1


- Claim: Burning time **at least** 3 hrs
- $\bar{x} = 2.96$ $n=42$, $\sigma=0.23$, $\alpha=.10$
- Null Hypothesis: $H_0: \mu \geq 3$
- Alt. Hypothesis: $H_1: \mu < 3$
- Test statistic:

$$Z_0 = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} = \frac{2.96 - 3}{0.23/\sqrt{42}} = -1.13$$

- Rejection region: $z_{\alpha} = z_{.10} = -1.282$
- P-value = $P(z < -1.13) = .1299$
- Fail to reject H_0



Modelos



Estimated (or predicted) y value

Estimate of the regression intercept


Estimate of the regression slope


Independent variable

Error term

$$y_i = b_0 + b_1 x + e$$


Y muchas más





CRISP-DM

Diagrama de Taylor (2017)



CRISP-DM

Diagrama de Taylor (2017)

Métricas y sus intervalos de confianza

Métricas

Mean squared error

$$\text{MSE} = \frac{1}{n} \sum_{t=1}^n e_t^2$$

Root mean squared error

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n e_t^2}$$

Mean absolute error

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |e_t|$$

Mean absolute percentage error

$$\text{MAPE} = \frac{100\%}{n} \sum_{t=1}^n \left| \frac{e_t}{y_t} \right|$$

Intervalos de confianza para las métricas

Supongamos que cree un modelo de series de tiempo y encontré sus errores.

Calculo su MAE y me da un valor de 3.

Pero, ¿cómo puedo estimar el intervalo de confianza para el MAE?

Intervalo de confianza normal para la media

$$\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$


Where,

$z_{\alpha/2}$ is the normal distribution value for a probability of $\alpha/2$ in each tail. This value is the z-score with $\alpha/2$ probability in the upper tail.

$\sigma/\text{Sqrt}(n)$ is the standard error

$\bar{x}$ is the sample mean – point estimate of the population mean

Bootstrap




K-Folds


K-folds	Accuracy	Precision	Recall	F-score
Fold-1	97.4%	97.4%	98.4%	97.9%
Fold-2	97.8%	96.2%	96.5%	96.3%
Fold-3	97.2%	96.3%	98.6%	97.4%
Fold-4	97.1%	96.4%	97.4%	96.9%
Fold-5	97.8%	97.9%	99.2%	98.5%
Fold-6	95.9%	96.3%	97.1%	96.7%
Fold-7	96.9%	96.8%	97.4%	97.1%
Fold-8	97.9%	97.5%	99.2%	98.3%
Fold-9	96.4%	96.9%	98.1%	97.5%
Fold-10	97.2%	97.3%	98.1%	97.7%
10-Fold Mean	97.1%	96.9%	98.0%	97.4%

Comparación y selección de modelos





A/B Testing




Boxplot de residuales



Pruebas de hipótesis para comparar poblaciones



Compararemos dos poblaciones emparejadas de forma no paramétrica: Wilcoxon signed rank test




The illustration on the left depicts a stopwatch at the top, symbolizing time or measurement. Below it, on a grid background, are four pairs of shapes: two dark circles, two dark diamonds, two black triangles, and two white pentagons. Each pair is connected by a horizontal line with two dots, representing a paired comparison. At the bottom, there are two stylized signatures, one in blue and one in black.

Wilcoxon Test

[*'wil-'käks-'on 'test*]


A nonparametric statistical test that compares two paired groups.

K-Fold Cross Validation




Selección e importancia de variables


Correlación




Importancia de variables en árboles




SHAPley values



Forward stepwise selection example with 5 variables:



Backward stepwise selection example with 5 variables:



ANOVA, Chi-Square test y otros

variable		Dependent Categorical	Numerical
Independent	Categorical	* Chi-square	* ANOVA
		* Cramer's V	* point-biserial corr
		* Phi Coeff	* z-test
		* Mann whitney U	* t-test
		* Mc nemar's	* Mann whitney U
		* Conchran Q	
	Numerical	* point-biserial corr	* Pearson corr
			* paired t-test

Ejemplos opcionales adicionales

Aplicaciones de ciencia de datos:

<https://www.xataka.com/n/nueve-industrias-que-aplican-ciencia-datos-para-solucionar-problemas-reales>

Popular Applications of Data Science:

<https://www.youtube.com/watch?v=b-filb3cps>

Otras temáticas de analítica: minería de textos, clustering y visualización:

<http://brandonrose.org/clustering>